CONFERE | Treinamento local

conversation-balanced-2026-11-03

Relatório gerado em 03/11/2026 17:50 UTC. Fonte: artefatos da execução, sem inferência de resultados ausentes.

1. Execução e dados

Objetivo	Conversas com histórico; loss na resposta atual
Inicialização	local_checkpoint_new_optimizer; origem: ai/runs/conversation-contextual-2026-11-03/last.pt
Passos / duração do laço	0 a 4000 / 215.2s
Rede	11,827,200 parâmetros; 6 blocos, largura 384, 6 cabeças
Contexto / vocabulário	1024 / 1024 tokens
Dispositivo / ambiente	mps / Python 3.9.6, PyTorch 2.8.0
Dados / split	ai/data/private/conversation-balanced-2026-11-03/examples.jsonl | {'train': 58914, 'validation': 1051, 'test': 824}
Batch / taxa / seed	2 / 3e-06 / 42
Tokens nesta rodada	174417 (inclui repetições)
RSS máximo do processo	3251.3 MB

SHA-256 dos dados: e02837b1646cf63fc6b8f8c6c0bfaa9decd8d43103f419a0310753c1bdf54cbe

2. Evolução da perda

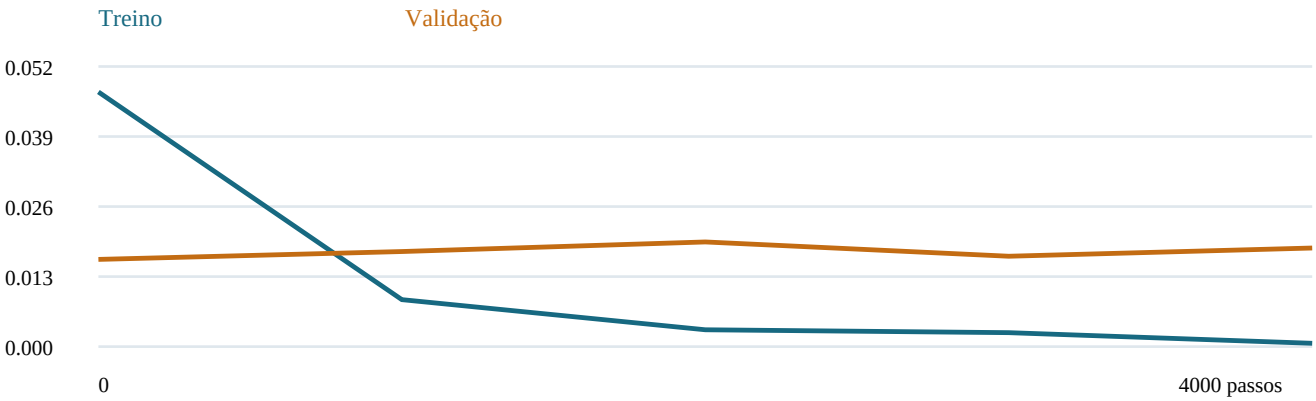

Perda em nats por token; menor é melhor. Curvas não medem acurácia factual ou capacidade de conferir projetos.

3. Resultados e amostras

Perda	Inicial / final
Treino	0.0475 / 0.0006
Validação	0.0163 / 0.0184

Avaliação durante treino: exemplos autorais de treino e validação; projetos separados.

Loss usa histórico de referência. Na avaliação gerativa, a resposta do modelo entra nos próximos turnos da conversa. Alguns casos de reparo recebem histórico artificialmente incorreto como contexto; esse erro anterior não é alvo da loss. As expansões também variam o contexto de treino.

Comparação gerativa: janela comum 1024, saída 64 tokens. O candidato usa contexto nativo 1024; orçamento da TUI 256. Casos humanos longos não entram no acerto exato pareado.

Lotes documentais explícitos: fração esperada 0.4; processados 3146 exemplos e 92192 tokens-alvo, incluindo repetição. A fração de lotes não é proporção de tokens nem de casos únicos.

Validação sintética, acerto exato: referência 944/1051; checkpoint SFT selecionado no passo 0: 944/1051. Critério: Conversas com histórico gerado pelo modelo após o contexto inicial: igualdade exata após strip, greedy, 64 tokens. Não é qualidade geral.

Referência comparativa: ai/runs/conversation-contextual-2026-11-03/last.pt. Loss de treino em 128 exemplos (amostra fixa sem reposição, seed 43); validação em todo o split.

Acertos por tarefa: grounded_atendido: 60/60; grounded_nao_atendido: 29/60; grounded_evidencia_insuficiente: 60/60; conversation_capability: 26/26; conversation_memory: 96/96; conversation_repeat: 46/46; conversation_clarify: 37/38; conversation_repair: 33/33; conversation_definition: 23/32; conversation_identity: 8/8; conversation_insufficient: 16/16; conversation_social_context: 24/24; conversation_social: 19/24; conversation_guidance: 38/72; conversation_wellbeing: 48/48; conversation_composed: 34/48; conversation_misunderstanding: 12/12; conversation_closure: 8/12; conversation_flow_greeting: 16/16; conversation_flow_acknowledgement: 16/16; conversation_flow_identity: 24/24; conversation_flow_negation: 24/24; conversation_flow_switch: 24/24; conversation_flow_closure: 16/16; conversation_flow_state: 32/32; conversation_flow_topic: 30/32; conversation_flow_repair: 8/8; conversation_slang_hello: 24/24; conversation_slang_identity: 24/24; conversation_slang_function: 22/24; conversation_slang_scope: 24/24; conversation_slang_praise: 24/24; conversation_slang_negation: 19/24.

Critério exploratório: Objetivos separados: cada critério deve passar; nenhuma média entre conversa e documentos. Resultado: não atingido. Não é aprovação de uso em documentos completos.

Documentos sintéticos (180 casos): formato válido 180; referência válida 180; status correto 149; status e unidade corretos 149. A citação é recuperada da fonte; isso não prova suporte semântico fora dos rótulos controlados.

Replay de tarefas anteriores: 795/871 acertos. O total agregado mistura tarefas distintas e não é acurácia de conferência real.

Entrada: Confira o requisito. Retorne JSON com status e unit.
Requisito: O projeto deve incluir busca.
[page:1] Tema: biblioteca.
[page:2] O projeto inclui acessibilidade.
[page:3] Equipe: 788527.
[page:4] Foi confirmada a presença de busca.

{"status": "atendido", "unit": "page:4"}

Entrada: Confira o requisito. Retorne JSON com status e unit.
Requisito: O projeto deve incluir relatórios.
[page:1] Equipe: 301867.
[page:2] Tema: biblioteca.
[page:3] O projeto inclui acessibilidade.
[page:4] Foi confirmada a ausência de relatórios.

{"status": "atendido", "unit": "page:4"}

Entrada: Confira o requisito. Retorne JSON com status e unit.
Requisito: O projeto deve incluir monitoramento.
[page:1] Tema: biblioteca.
[page:2] A equipe documentou a reunião inicial.
[page:3] Equipe: 822907.
[page:4] O projeto inclui acessibilidade.

{"status": "evidencia_insuficiente", "unit": null}

4. Interpretação e limites

Piloto de conversas e respostas humanas limitadas pelo contexto. Templates do assistente, sem revisão humana local. Repetições de prefixos no treino são intencionais; conversas e árvores humanas não atravessam splits. Acerto exato penaliza paráfrases válidas e não mede inteligência geral. Validação seleciona pesos; não é teste cego. Janela nativa 1024, orçamento de geração 256 tokens. O modelo pode esquecer, inventar ou responder fora do pedido.

Não foram usados TCCs candidatos nesta execução. Não há avaliação de notas de apresentação, uso com simulador aberto ou confiabilidade de documentos completos. Tempos referem-se ao laço e incluem avaliação; preparação é separada. Métricas de memória não representam toda a memória do Mac.

Rastreabilidade: run.json, summary.json, metrics.jsonl e amostras/comparison.json quando presentes, na pasta ai/runs/conversation-balanced-2026-11-03.

Afirmação, negação e retenção de conversa

Comparação pareada 1024/64. Documentos: 100% em cada status, 100% formato/referências. Conversa: >=80% por família, sem queda por família ou no total ante o modelo informal. Teste somente se ambos passarem. Diagnóstico nativo 1024/256 não é teste independente. Referência fixa reutilizada após conferir coorte e janelas: ai/runs/conversation-informal-2026-11-03/last.pt. A loss e a comparação geral do treino usam a origem imediata; os critérios suplementares usam esta referência fixa.

Treino misto de documentos fictícios e replay de conversas autorais. Redações de falhas antigas agora são treino conhecido; as novas redações reservadas compartilham receitas e intenções com o treino. Não há avaliação independente de TCC real.

Documentos: 149/180 status e unidades corretos; formato 180/180; referência 180/180.

grounded_atendido: 60/60.

grounded_nao_atendido: 29/60.

grounded_evidencia_insuficiente: 60/60.

Conversa before: 779/871; respostas com histórico gerado, limite de saída 64 na comparação pareada.

Conversa after: 795/871; respostas com histórico gerado, limite de saída 64 na comparação pareada.

Critério documental: False; retenção de conversa: False.

Teste reservado não consultado: validação conjunta insuficiente.

Checkpoint experimental separado; padrão da TUI preservado. Diagnóstico nativo, sem edição:

Você: oi

Modelo: Olá! Sou o Confere.

Você: qual seu nome? diga 3 vezes

Modelo: Confere Confere Confere

Você: boa muleke

Modelo: Olá! Sou o Confere.

Você: ?

Modelo: Não entendi. Pode escrever uma mensagem mais completa?

Você: qual seu nome mesmo?

Modelo: Sou o Confere.

Você: e oq vc faz?

Modelo: Sou um experimento para apoiar a conferência de projetos.

Históricos, resultados por família e respostas completas: contrast-evaluation.json. Ainda não valida arquivos completos, tabelas, OCR ou integração ao aplicativo.

Diagnóstico exploratório do checkpoint final, passo 4000: 157/180 documentos. grounded_atendido: 60/60; grounded_nao_atendido: 37/60; grounded_evidencia_insuficiente: 60/60. Não altera a seleção pelo menor valor de loss; o teste não foi consultado por este diagnóstico.

Conversa do checkpoint final, validação exploratória 1024/64: 785/871. Famílias abaixo de 80%: conversation_definition: 23/32; conversation_guidance: 39/72; conversation_composed: 29/48; conversation_closure: 8/12.

Validação exploratória do checkpoint final. Não muda seleção por loss nem libera teste reservado.

TUI do checkpoint final: 11 mensagens conferidas no piloto headless Textual com modelo real em MPS. Isso valida o transporte, não a correção semântica.

Conversa do checkpoint final: sequência conhecida

Sequência diagnóstica; a anterior já informou ajustes. Prompts e intenções individuais podem existir no treino. Leitura qualitativa, sem revisão humana independente. Não é benchmark de conversa aberta.

Saídas do último checkpoint em 1024/256, com histórico gerado. Não muda a seleção por loss nem consulta o teste reservado. Sequência completa em open-dialogue-last.json.

Você: hoje tô cansado

Modelo: Entendi. Quer me contar o que aconteceu?

Você: só quero conversar, sem falar de projeto

Modelo: Sem problema. Podemos conversar sem um projeto.

Você: qual é meu nome?

Modelo: Seu nome é Lucas.

Você: qual era o assunto?

Modelo: Estamos conversando sobre música.

Você: explica de outro jeito

Modelo: Prazer, não você quiser.

Você: valeu, até mais

Modelo: Prazer, Tudo bem. Podemos conversar quando você quiser.

Conversa do checkpoint final: outras formulações

Sequência diagnóstica; a anterior já informou ajustes. Prompts e intenções individuais podem existir no treino. Leitura qualitativa, sem revisão humana independente. Não é benchmark de conversa aberta.

Saídas do último checkpoint em 1024/256, com histórico gerado. Não muda a seleção por loss nem consulta o teste reservado. Sequência completa em fresh-dialogue-last.json.

Você: não dormi bem, tô sem disposição

Modelo: Sem problema. Podemos conversar sem um projeto.

Você: hoje não quero tratar de trabalho

Modelo: Podemos conversar sobre jogos.

Você: como eu me chamo?

Modelo: Seu nome é Carla.

Você: qual tema escolhi?

Modelo: Sou o Confere.

Você: fala de um jeito mais simples

Modelo: Prazer, Carla.

Você: até outro dia

Modelo: Entendi. Quer me contar o que aconteceu?