CONFERE | Treinamento local

conversation-flow-restarts-2026-11-02

Relatório gerado em 02/11/2026 23:21 UTC. Fonte: artefatos da execução, sem inferência de resultados ausentes.

1. Execução e dados

Objetivo	Conversas com histórico; loss na resposta atual
Inicialização	local_checkpoint_new_optimizer; origem: ai/runs/conversation-flow-public-smallbatch-2026-11-02/best.pt
Passos / duração do laço	0 a 2000 / 199.6s
Rede	11,827,200 parâmetros; 6 blocos, largura 384, 6 cabeças
Contexto / vocabulário	1024 / 1024 tokens
Dispositivo / ambiente	mps / Python 3.9.6, PyTorch 2.8.0
Dados / split	ai/data/private/conversation-flow-restarts-1024/examples.jsonl | {'train': 173810, 'validation': 729, 'test': 597}
Batch / taxa / seed	2 / 1e-05 / 42
Tokens nesta rodada	98840 (inclui repetições)
RSS máximo do processo	3225.9 MB

SHA-256 dos dados: 4ecfb8692e1f47547aab09739530d3615f0f1b5d9a679d0a38929bc318c60a74

2. Evolução da perda

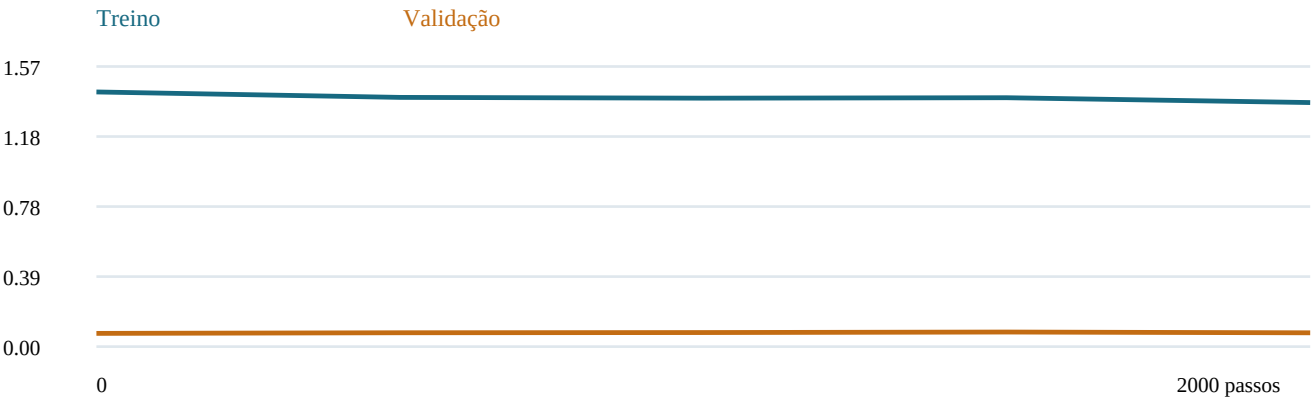

Perda em nats por token; menor é melhor. Curvas não medem acurácia factual ou capacidade de conferir projetos.

3. Resultados e amostras

Perda	Inicial / final
Treino	1.4246 / 1.3653
Validação	0.0740 / 0.0772

Avaliação durante treino: exemplos autorais de treino e validação; projetos separados.

Loss usa histórico de referência. Na avaliação gerativa, a resposta do modelo entra nos próximos turnos da conversa. Alguns casos de reparo recebem histórico artificialmente incorreto como contexto; esse erro anterior não é alvo da loss. As expansões também variam o contexto de treino.

Fonte humana: https://huggingface.co/datasets/OpenAssistant/oasst2, Apache-2.0, revisão 179dd21fc55192153d94adb0e0ce8f69e222bf75. Mensagens pt-BR na fonte: 2699; respostas aproveitadas: treino 73, validação 2, teste 7. A mistura é majoritariamente sintética.

Fonte pública adicional: https://huggingface.co/datasets/nicholasKluge/instruct-aira-dataset-v3, Apache-2.0, revisão 1ca52371453cc9e52b650ba4314f2ca0a69f58ba. Respostas geradas por modelos, sem anotação humana; 14751 caminhos de treino incluídos. Validação e teste públicos permanecem em arquivo reservado separado, fora desta execução.

Lotes públicos esperados: 0.05; processados 210 exemplos e 32290 tokens-alvo, com repetição. Os dados públicos não são respostas programadas na inferência nem pesos pré-treinados importados.

Comparação gerativa: janela comum 1024, saída 64 tokens. O candidato usa contexto nativo 1024; orçamento da TUI 256. Casos humanos longos não entram no acerto exato pareado.

Amostragem humana em lotes homogêneos: fração esperada 0.01; 26 exemplos processados com repetição, 3817 tokens-alvo humanos. Validação humana de loss: 2 exemplos, insuficiente para qualidade geral.

Loss humana de referência: inicial 4.8079; final 4.9372. A loss agregada dominada por templates não comprova melhora no diálogo humano.

Validação sintética, acerto exato: referência 541/727; checkpoint SFT selecionado no passo 0: 696/727. Critério: Conversas com histórico gerado pelo modelo após o contexto inicial: igualdade exata após strip, greedy, 64 tokens. Não é qualidade geral.

Decisão experimental: Reprovado na avaliação ampliada de diálogos; padrão da TUI preservado.

Referência comparativa: ai/runs/conversation-identity-2026-11-02/last.pt. Loss de treino em 128 exemplos (amostra fixa sem reposição, seed 43); validação em todo o split.

Acertos por tarefa: conversation_capability: 25/26; conversation_memory: 96/96; conversation_repeat: 46/46; conversation_clarify: 38/38; conversation_repair: 33/33; conversation_definition: 31/32; conversation_identity: 8/8; conversation_insufficient: 16/16; conversation_social_context: 24/24; conversation_social: 21/24; conversation_guidance: 60/72; conversation_wellbeing: 48/48; conversation_composed: 46/48; conversation_misunderstanding: 12/12; conversation_closure: 12/12; conversation_flow_greeting: 10/16; conversation_flow_acknowledgement: 16/16; conversation_flow_identity: 24/24; conversation_flow_negation: 23/24; conversation_flow_switch: 24/24; conversation_flow_closure: 12/16; conversation_flow_state: 32/32; conversation_flow_topic: 31/32; conversation_flow_repair: 8/8.

Critério exploratório: Conversas sintéticas: ao menos 80% em cada família, com histórico gerado pelo modelo. Resultado: não atingido. Não é aprovação de uso em documentos completos.

Entrada: e aí, Confere!

Olá! Sou o Confere.

Entrada: o que consigo fazer com você?

Sou um experimento para apoiar a conferência de projetos.

Entrada: como começo?

Escolha um requisito e um trecho do documento.

4. Interpretação e limites

Piloto de conversas e respostas humanas limitadas pelo contexto. Templates do assistente, sem revisão humana local. Repetições de prefixos no treino são intencionais; conversas e árvores humanas não atravessam splits. Acerto exato penaliza paráfrases válidas e não mede inteligência geral. Validação seleciona pesos; não é teste cego. Janela nativa 1024, orçamento de geração 256 tokens. O modelo pode esquecer, inventar ou responder fora do pedido.

Não foram usados TCCs candidatos nesta execução. Não há avaliação de notas de apresentação, uso com simulador aberto ou confiabilidade de documentos completos. Tempos referem-se ao laço e incluem avaliação; preparação é separada. Métricas de memória não representam toda a memória do Mac.

Rastreabilidade: run.json, summary.json, metrics.jsonl e amostras/comparison.json quando presentes, na pasta ai/runs/conversation-flow-restarts-2026-11-02.

5. Diálogos completos com histórico nativo

Primeiro candidato best/last que passe validação: >=80% por família nova, >=50% conversas completas, zero truncamento, 6/6 regressões, retenção legada sem queda e >=80% por família legada. Teste final uma vez após seleção, com os mesmos limites por família e conversa.

Janela 1024 e saída até 256 tokens; cada resposta gerada entra no próximo turno. Os cenários são autorais, sem revisão humana independente. O acerto exato não mede conversa aberta. As mesmas situações e respostas podem aparecer com outras palavras no treino.

Referência: turnos 27/192; conversas inteiras 0/24; turnos descartados 0.

Validação pública separada: 64 caminhos, um por conversa, sem contexto exato repetido no treino público. Loss da referência 4.3485; histórico de referência. Essa loss não participa da decisão de adoção e não é avaliação humana de qualidade.

Candidato passo 0: turnos 181/192; conversas inteiras 16/24; turnos descartados 0.

Retenção legada na janela comum 256: 516/535; regressões conhecidas 6/6; critério de validação não atingido.

Loss nos mesmos caminhos públicos reservados de validação: 2.9018.

Candidato passo 2000: turnos 178/192; conversas inteiras 18/24; turnos descartados 0.

Retenção legada na janela comum 256: 501/535; regressões conhecidas 6/6; critério de validação não atingido.

Loss nos mesmos caminhos públicos reservados de validação: 2.8935.

Teste reservado não consultado: nenhum candidato passou na validação ampliada.

Adoção: reprovada; TUI preservada.

Você: olá, podemos conversar?

Modelo: Sou o Confere.

Alvo autoral: Olá! Sou o Confere.

Você: retificando, ainda estou sem um projeto

Modelo: Sem problema. Podemos conversar sem um projeto.

Alvo autoral: Entendi: você ainda não tem um projeto.

Os históricos completos, respostas, famílias e falhas de cada candidato estão em flow-evaluation.json. Teste consultado não deve virar fonte de ajuste numa repetição desta avaliação.