CONFERE | Treinamento local

conversation-informal-2026-11-03

Relatório gerado em 03/11/2026 13:34 UTC. Fonte: artefatos da execução, sem inferência de resultados ausentes.

1. Execução e dados

Objetivo	Conversas com histórico; loss na resposta atual
Inicialização	local_checkpoint_new_optimizer; origem: ai/runs/conversation-flow-restarts-2026-11-02/last.pt
Passos / duração do laço	0 a 4000 / 248.3s
Rede	11,827,200 parâmetros; 6 blocos, largura 384, 6 cabeças
Contexto / vocabulário	1024 / 1024 tokens
Dispositivo / ambiente	mps / Python 3.9.6, PyTorch 2.8.0
Dados / split	ai/data/private/conversation-informal-safe-2026-11-03/examples.jsonl | {'train': 202110, 'validation': 873, 'test': 741}
Batch / taxa / seed	2 / 2e-05 / 42
Tokens nesta rodada	177421 (inclui repetições)
RSS máximo do processo	4217.6 MB

SHA-256 dos dados: 0a3b98cc2780764c526d3fd42cc71e155fef52dc64c6d8b411fc961bcbe4afd3

2. Evolução da perda

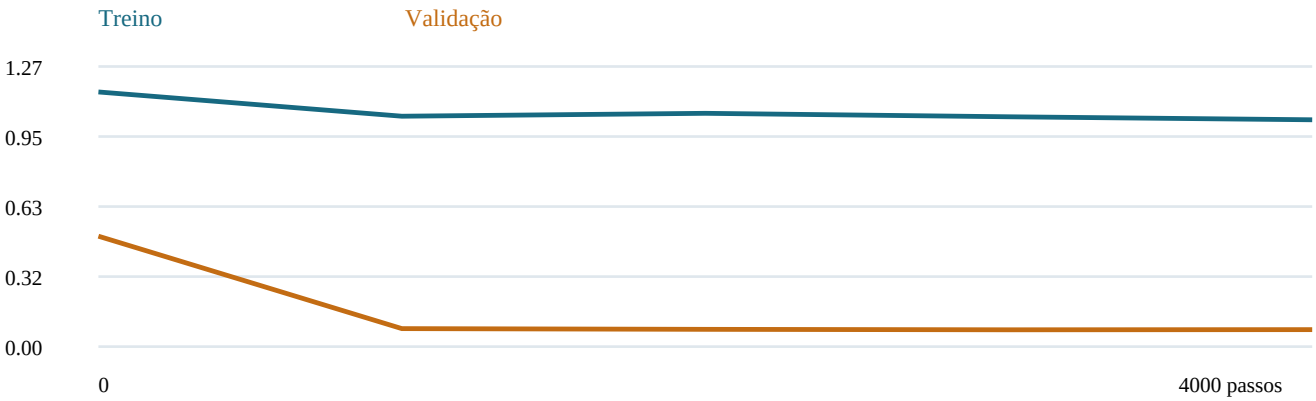

Perda em nats por token; menor é melhor. Curvas não medem acurácia factual ou capacidade de conferir projetos.

3. Resultados e amostras

Perda	Inicial / final
Treino	1.1545 / 1.0284
Validação	0.5006 / 0.0770

Avaliação durante treino: exemplos autorais de treino e validação; projetos separados.

Loss usa histórico de referência. Na avaliação gerativa, a resposta do modelo entra nos próximos turnos da conversa. Alguns casos de reparo recebem histórico artificialmente incorreto como contexto; esse erro anterior não é alvo da loss. As expansões também variam o contexto de treino.

Fonte humana: https://huggingface.co/datasets/OpenAssistant/oasst2, Apache-2.0, revisão 179dd21fc55192153d94adb0e0ce8f69e222bf75. Mensagens pt-BR na fonte: 2699; respostas aproveitadas: treino 73, validação 2, teste 7. A mistura é majoritariamente sintética.

Fonte pública adicional: https://huggingface.co/datasets/nicholasKluge/instruct-aira-dataset-v3, Apache-2.0, revisão 1ca52371453cc9e52b650ba4314f2ca0a69f58ba. Respostas geradas por modelos, sem anotação humana; 14751 caminhos de treino incluídos. Validação e teste públicos permanecem em arquivo reservado separado, fora desta execução.

Lotes públicos esperados: 0.03; processados 232 exemplos e 35170 tokens-alvo, com repetição. Os dados públicos não são respostas programadas na inferência nem pesos pré-treinados importados.

Comparação gerativa: janela comum 1024, saída 64 tokens. O candidato usa contexto nativo 1024; orçamento da TUI 256. Casos humanos longos não entram no acerto exato pareado.

Amostragem humana em lotes homogêneos: fração esperada 0.01; 64 exemplos processados com repetição, 9313 tokens-alvo humanos. Validação humana de loss: 2 exemplos, insuficiente para qualidade geral.

Loss humana de referência: inicial 4.9372; final 4.8688. A loss agregada dominada por templates não comprova melhora no diálogo humano.

Validação sintética, acerto exato: referência 715/871; checkpoint SFT selecionado no passo 3000: 752/871. Critério: Conversas com histórico gerado pelo modelo após o contexto inicial: igualdade exata após strip, greedy, 64 tokens. Não é qualidade geral.

Decisão experimental: Critérios ampliados não atingidos; checkpoint experimental e padrão da TUI preservado.

Referência comparativa: ai/runs/conversation-flow-restarts-2026-11-02/last.pt. Loss de treino em 128 exemplos (amostra fixa sem reposição, seed 43); validação em todo o split.

Acertos por tarefa: conversation_capability: 26/26; conversation_memory: 96/96; conversation_repeat: 45/46; conversation_clarify: 35/38; conversation_repair: 33/33; conversation_definition: 25/32; conversation_identity: 8/8; conversation_insufficient: 16/16; conversation_social_context: 24/24; conversation_social: 19/24; conversation_guidance: 61/72; conversation_wellbeing: 42/48; conversation_composed: 37/48; conversation_misunderstanding: 5/12; conversation_closure: 9/12; conversation_flow_greeting: 14/16; conversation_flow_acknowledgement: 16/16; conversation_flow_identity: 24/24; conversation_flow_negation: 21/24; conversation_flow_switch: 23/24; conversation_flow_closure: 16/16; conversation_flow_state: 32/32; conversation_flow_topic: 24/32; conversation_flow_repair: 8/8; conversation_slang_hello: 14/24; conversation_slang_identity: 18/24; conversation_slang_function: 14/24; conversation_slang_scope: 15/24; conversation_slang_praise: 14/24; conversation_slang_negation: 18/24.

Critério exploratório: Conversas sintéticas: ao menos 80% em cada família, com histórico gerado pelo modelo. Resultado: não atingido. Não é aprovação de uso em documentos completos.

Entrada: e aí, Confere!

Olá! Sou o Confere.

Entrada: o que consigo fazer com você?

Sou um experimento para apoiar a conferência de projetos.

Entrada: como começo?

Escolha um requisito e um trecho do documento.

4. Interpretação e limites

Piloto de conversas e respostas humanas limitadas pelo contexto. Templates do assistente, sem revisão humana local. Repetições de prefixos no treino são intencionais; conversas e árvores humanas não atravessam splits. Acerto exato penaliza paráfrases válidas e não mede inteligência geral. Validação seleciona pesos; não é teste cego. Janela nativa 1024, orçamento de geração 256 tokens. O modelo pode esquecer, inventar ou responder fora do pedido.

Não foram usados TCCs candidatos nesta execução. Não há avaliação de notas de apresentação, uso com simulador aberto ou confiabilidade de documentos completos. Tempos referem-se ao laço e incluem avaliação; preparação é separada. Métricas de memória não representam toda a memória do Mac.

Rastreabilidade: run.json, summary.json, metrics.jsonl e amostras/comparison.json quando presentes, na pasta ai/runs/conversation-informal-2026-11-03.

Verificação integrada: piloto headless do Textual com modelo real em mps, passo 4000; 10 envios conferidos. Contexto 1024, geração 256.

Português informal e perguntas de continuidade

Validação: >=80% por família e >=50% diálogos completos nas coortes informal e fluxo anterior, zero descarte; legado >=514/535 e sem queda ante referência, >=80% por família. Teste informal reservado somente após seleção. Casos conhecidos são diagnóstico, não teste cego.

Variações são aplicadas aos dados de treino, sem substituição de texto na CLI. Formulações de validação e teste são separadas; intenções e respostas autorais são compartilhadas. Isso mede adaptação controlada, não domínio geral de gírias. Os históricos usam as respostas da própria rede.

A validação informal contém 144 turnos, 12 formulações distintas e 90 contextos de referência distintos. Há repetição de receitas de diálogo; as contagens não representam situações semanticamente independentes.

Referência, informal: 36/144 turnos; 0/24 conversas completas; 0 turnos descartados.

Referência, flow: 178/192 turnos; 18/24 conversas completas; 0 turnos descartados.

Referência, legacy: 501/535 turnos; 151/176 conversas completas; 0 turnos descartados.

Passo 3000, informal: 93/144 turnos; 3/24 conversas completas; 0 turnos descartados.

Passo 3000, flow: 178/192 turnos; 12/24 conversas completas; 0 turnos descartados.

Passo 3000, legacy: 481/535 turnos; 133/176 conversas completas; 0 turnos descartados.

Critério conjunto: não atingido.

Passo 4000, informal: 97/144 turnos; 4/24 conversas completas; 0 turnos descartados.

Passo 4000, flow: 184/192 turnos; 16/24 conversas completas; 0 turnos descartados.

Passo 4000, legacy: 498/535 turnos; 148/176 conversas completas; 0 turnos descartados.

Critério conjunto: não atingido.

Teste reservado não consultado: nenhum candidato passou na validação conjunta.

Conclusão: experimental; padrão da TUI preservado.

Diagnóstico conhecido, candidato final, sem edição de respostas:

Você: e oq vc faz?

Modelo: Sou um experimento para apoiar a conferência de projetos.

Você: e o que voce faz?

Modelo: Sou o Confere.

Você: que tipo de projetos?

Modelo: Projetos acadêmicos com requisitos e documentos. A análise de arquivos completos ainda não está validada.

Você: quer ser meu amigo?

Modelo: Posso ter entendido em projetos.

Resultados por família, respostas e históricos completos: informal-evaluation.json. A CLI não foi alterada. Não houve avaliação de anexos completos nesta etapa.