CONFERE | Treinamento local

conversation-recovery-2026-11-03

Relatório gerado em 03/11/2026 17:23 UTC. Fonte: artefatos da execução, sem inferência de resultados ausentes.

1. Execução e dados

Objetivo	Conversas com histórico; loss na resposta atual
Inicialização	local_checkpoint_new_optimizer; origem: ai/runs/document-paired-2026-11-03/last.pt
Passos / duração do laço	0 a 4780 / 484.4s
Rede	11,827,200 parâmetros; 6 blocos, largura 384, 6 cabeças
Contexto / vocabulário	1024 / 1024 tokens
Dispositivo / ambiente	mps / Python 3.9.6, PyTorch 2.8.0
Dados / split	ai/data/private/conversation-recovery-2026-11-03/examples.jsonl | {'train': 74281, 'validation': 1051, 'test': 824}
Batch / taxa / seed	2 / 1e-05 / 42
Tokens nesta rodada	405066 (inclui repetições)
RSS máximo do processo	4334.2 MB

SHA-256 dos dados: 4b10777cd992d7cbae6242577766769e0d59478e0a122bc4a5248d43a6afd574

2. Evolução da perda

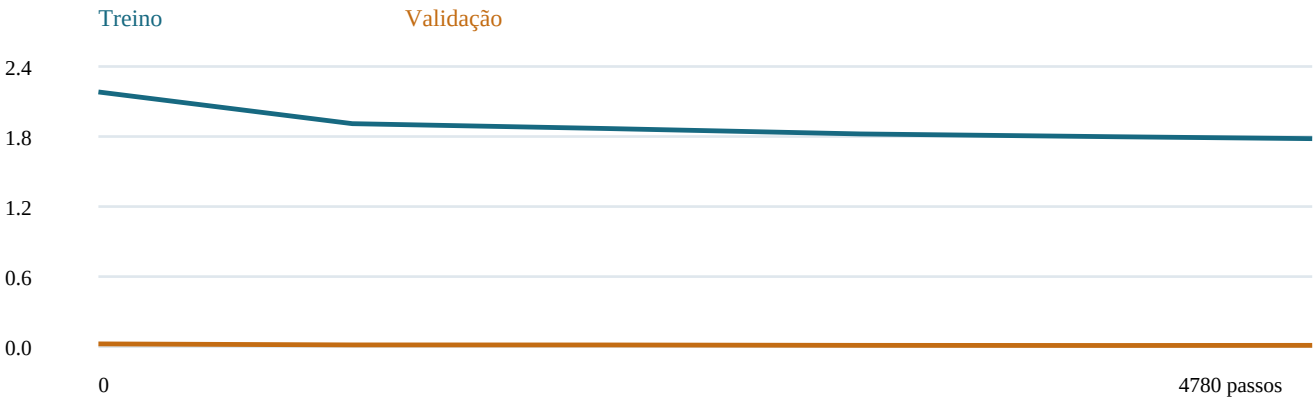

Perda em nats por token; menor é melhor. Curvas não medem acurácia factual ou capacidade de conferir projetos.

3. Resultados e amostras

Perda	Inicial / final
Treino	2.1589 / 1.7631
Validação	0.0230 / 0.0107

Avaliação durante treino: exemplos autorais de treino e validação; projetos separados.

Loss usa histórico de referência. Na avaliação gerativa, a resposta do modelo entra nos próximos turnos da conversa. Alguns casos de reparo recebem histórico artificialmente incorreto como contexto; esse erro anterior não é alvo da loss. As expansões também variam o contexto de treino.

Fonte humana: https://huggingface.co/datasets/OpenAssistant/oasst2, Apache-2.0, revisão 179dd21fc55192153d94adb0e0ce8f69e222bf75. Mensagens pt-BR na fonte: 2699; respostas aproveitadas: treino 73, validação 0, teste 0. A mistura é majoritariamente sintética.

Fonte pública adicional: https://huggingface.co/datasets/nicholasKluge/instruct-aira-dataset-v3, Apache-2.0, revisão 1ca52371453cc9e52b650ba4314f2ca0a69f58ba. Respostas geradas por modelos, sem anotação humana; 14751 caminhos de treino incluídos. Validação e teste públicos permanecem em arquivo reservado separado, fora desta execução.

Lotes públicos esperados: 0.15; processados 1438 exemplos e 219093 tokens-alvo, com repetição. Os dados públicos não são respostas programadas na inferência nem pesos pré-treinados importados.

Comparação gerativa: janela comum 1024, saída 64 tokens. O candidato usa contexto nativo 1024; orçamento da TUI 256. Casos humanos longos não entram no acerto exato pareado.

Amostragem humana em lotes homogêneos: fração esperada 0.03; 256 exemplos processados com repetição, 36464 tokens-alvo humanos. Validação humana de loss: 0 exemplos, insuficiente para qualidade geral.

Validação sintética, acerto exato: referência 955/1051; checkpoint SFT selecionado no passo 4000: 986/1051. Critério: Conversas com histórico gerado pelo modelo após o contexto inicial: igualdade exata após strip, greedy, 64 tokens. Não é qualidade geral.

Referência comparativa: ai/runs/document-paired-2026-11-03/last.pt. Loss de treino em 128 exemplos (amostra fixa sem reposição, seed 43); validação em todo o split.

Acertos por tarefa: grounded_atendido: 60/60; grounded_nao_atendido: 46/60; grounded_evidencia_insuficiente: 60/60; conversation_capability: 26/26; conversation_memory: 96/96; conversation_repeat: 46/46; conversation_clarify: 38/38; conversation_repair: 33/33; conversation_definition: 31/32; conversation_identity: 8/8; conversation_insufficient: 16/16; conversation_social_context: 24/24; conversation_social: 20/24; conversation_guidance: 60/72; conversation_wellbeing: 48/48; conversation_composed: 45/48; conversation_misunderstanding: 10/12; conversation_closure: 10/12; conversation_flow_greeting: 16/16; conversation_flow_acknowledgement: 16/16; conversation_flow_identity: 24/24; conversation_flow_negation: 24/24; conversation_flow_switch: 24/24; conversation_flow_closure: 16/16; conversation_flow_state: 32/32; conversation_flow_topic: 30/32; conversation_flow_repair: 8/8; conversation_slang_hello: 13/24; conversation_slang_identity: 20/24; conversation_slang_function: 18/24; conversation_slang_scope: 23/24; conversation_slang_praise: 23/24; conversation_slang_negation: 22/24.

Critério exploratório: Objetivos separados: cada critério deve passar; nenhuma média entre conversa e documentos. Resultado: não atingido. Não é aprovação de uso em documentos completos.

Documentos sintéticos (180 casos): formato válido 180; referência válida 180; status correto 166; status e unidade corretos 166. A citação é recuperada da fonte; isso não prova suporte semântico fora dos rótulos controlados.

Replay de tarefas anteriores: 820/871 acertos. O total agregado mistura tarefas distintas e não é acurácia de conferência real.

Entrada: Confira o requisito. Retorne JSON com status e unit.
Requisito: O projeto deve incluir busca.
[page:1] Tema: biblioteca.
[page:2] O projeto inclui acessibilidade.
[page:3] Equipe: 788527.
[page:4] Foi confirmada a presença de busca.

{"status": "atendido", "unit": "page:4"}

Entrada: Confira o requisito. Retorne JSON com status e unit.
Requisito: O projeto deve incluir relatórios.
[page:1] Equipe: 301867.
[page:2] Tema: biblioteca.
[page:3] O projeto inclui acessibilidade.
[page:4] Foi confirmada a ausência de relatórios.

{"status": "nao_atendido", "unit": "page:4"}

Entrada: Confira o requisito. Retorne JSON com status e unit.
Requisito: O projeto deve incluir monitoramento.
[page:1] Tema: biblioteca.
[page:2] A equipe documentou a reunião inicial.
[page:3] Equipe: 822907.
[page:4] O projeto inclui acessibilidade.

{"status": "evidencia_insuficiente", "unit": null}

4. Interpretação e limites

Piloto de conversas e respostas humanas limitadas pelo contexto. Templates do assistente, sem revisão humana local. Repetições de prefixos no treino são intencionais; conversas e árvores humanas não atravessam splits. Acerto exato penaliza paráfrases válidas e não mede inteligência geral. Validação seleciona pesos; não é teste cego. Janela nativa 1024, orçamento de geração 256 tokens. O modelo pode esquecer, inventar ou responder fora do pedido.

Não foram usados TCCs candidatos nesta execução. Não há avaliação de notas de apresentação, uso com simulador aberto ou confiabilidade de documentos completos. Tempos referem-se ao laço e incluem avaliação; preparação é separada. Métricas de memória não representam toda a memória do Mac.

Rastreabilidade: run.json, summary.json, metrics.jsonl e amostras/comparison.json quando presentes, na pasta ai/runs/conversation-recovery-2026-11-03.

Afirmação, negação e retenção de conversa

Comparação pareada 1024/64. Documentos: 100% em cada status, 100% formato/referências. Conversa: >=80% por família, sem queda por família ou no total ante o modelo informal. Teste somente se ambos passarem. Diagnóstico nativo 1024/256 não é teste independente. Referência fixa reutilizada após conferir coorte e janelas: ai/runs/conversation-informal-2026-11-03/last.pt. A loss e a comparação geral do treino usam a origem imediata; os critérios suplementares usam esta referência fixa.

Treino misto de documentos fictícios e replay de conversas autorais. Redações de falhas antigas agora são treino conhecido; as novas redações reservadas compartilham receitas e intenções com o treino. Não há avaliação independente de TCC real.

Documentos: 166/180 status e unidades corretos; formato 180/180; referência 180/180.

grounded_atendido: 60/60.

grounded_nao_atendido: 46/60.

grounded_evidencia_insuficiente: 60/60.

Conversa before: 779/871; respostas com histórico gerado, limite de saída 64 na comparação pareada.

Conversa after: 820/871; respostas com histórico gerado, limite de saída 64 na comparação pareada.

Critério documental: False; retenção de conversa: False.

Teste reservado não consultado: validação conjunta insuficiente.

Checkpoint experimental separado; padrão da TUI preservado. Diagnóstico nativo, sem edição:

Você: oi

Modelo: Olá! Sou o Confere.

Você: qual seu nome? diga 3 vezes

Modelo: Confere Confere Confere

Você: boa muleke

Modelo: Posso ter entendido errado. Pode me dizer o que devo corrigir?

Você: ?

Modelo: Não tenho informação suficiente para responder.

Você: qual seu nome mesmo?

Modelo: Sou o Confere.

Você: e oq vc faz?

Modelo: Sou um experimento para apoiar a conferência de projetos.

Históricos, resultados por família e respostas completas: contrast-evaluation.json. Ainda não valida arquivos completos, tabelas, OCR ou integração ao aplicativo.

Diagnóstico de conversa com contexto gerado

Sequência composta após preparar o corpus; prompts e intenções individuais podem existir no treino. Leitura qualitativa, sem revisão humana independente. Não é benchmark de conversa aberta.

Janela nativa 1024, até 256 tokens por resposta. Histórico independente para cada modelo; as próprias respostas influenciam os turnos seguintes. Casos selecionados abaixo sem edição; sequência completa em open-dialogue.json. Acerto nos templates não prova conversa natural.

Você: hoje tô cansado

Origem imediata: Entendi errado. Pode reformular o pedido?

Candidato: Obrigado! Fico feliz em ajudar.

Você: só quero conversar, sem falar de projeto

Origem imediata: Tudo bem. Podemos conversar quando você quiser.

Candidato: Sem problema. Podemos falar de objetivos, requisitos ou evidências.

Você: qual é meu nome?

Origem imediata: Sou o Confere.

Candidato: Sou o Confere.

Você: qual era o assunto?

Origem imediata: Claro. Sobre o que você quer conversar?

Candidato: Claro. Sobre o que você quer conversar?

Você: explica de outro jeito

Origem imediata: Claro. Podemos conversar quando você quiser.

Candidato: Podemos conversar sobre estudos.

Você: valeu, até mais

Origem imediata: Tudo bem. Podemos conversar quando você quiser.

Candidato: Tudo bem. Podemos conversar quando você quiser.