CONFERE | Treinamento local

conversation-robust-2026-11-02

Relatório gerado em 02/11/2026 18:20 UTC. Fonte: artefatos da execução, sem inferência de resultados ausentes.

1. Execução e dados

Objetivo	Conversas com histórico; loss na resposta atual
Inicialização	local_checkpoint_new_optimizer; origem: ai/runs/conversation-curriculum-1024-2026-11-02/best.pt
Passos / duração do laço	0 a 6000 / 593.5s
Rede	11,827,200 parâmetros; 6 blocos, largura 384, 6 cabeças
Contexto / vocabulário	1024 / 1024 tokens
Dispositivo / ambiente	mps / Python 3.9.6, PyTorch 2.8.0
Dados / split	ai/data/private/conversation-robust-1024/examples.jsonl | {'train': 24091, 'validation': 537, 'test': 405}
Batch / taxa / seed	16 / 3e-05 / 42
Tokens nesta rodada	1677017 (inclui repetições)
RSS máximo do processo	2686.3 MB

SHA-256 dos dados: 6aeb0fd069d27dae1044c612157178bf5c2cc3fc00de7a53f936b2efb24de529

2. Evolução da perda

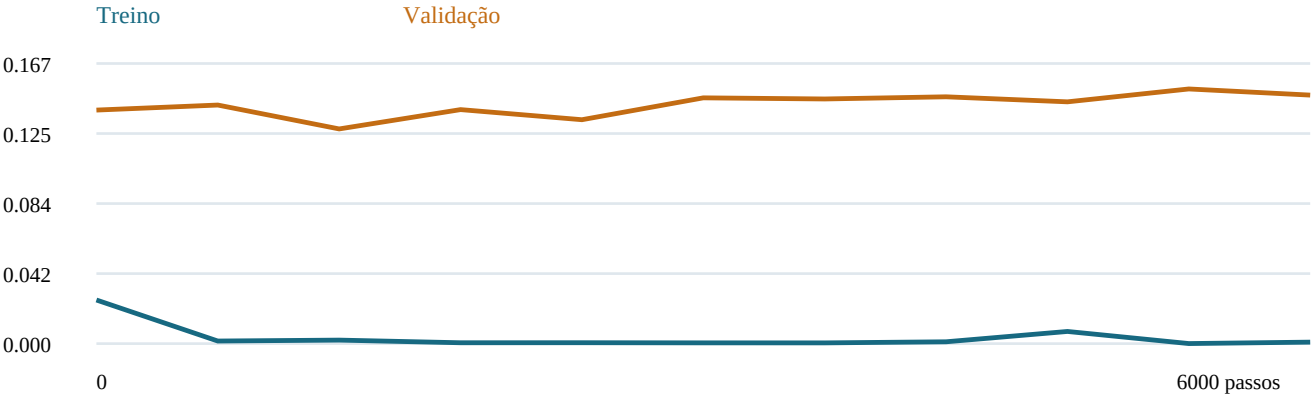

Perda em nats por token; menor é melhor. Curvas não medem acurácia factual ou capacidade de conferir projetos.

3. Resultados e amostras

Perda	Inicial / final
Treino	0.0260 / 0.0009
Validação	0.1393 / 0.1482

Avaliação durante treino: exemplos autorais de treino e validação; projetos separados.

Loss usa histórico de referência. Na avaliação gerativa, a resposta do modelo entra nos próximos turnos da conversa. Alguns casos de reparo recebem histórico artificialmente incorreto como contexto; esse erro anterior não é alvo da loss. As expansões também variam o contexto de treino.

Fonte humana: https://huggingface.co/datasets/OpenAssistant/oasst2, Apache-2.0, revisão 179dd21fc55192153d94adb0e0ce8f69e222bf75. Mensagens pt-BR na fonte: 2699; respostas aproveitadas: treino 73, validação 2, teste 7. A mistura é majoritariamente sintética.

Comparação gerativa: janela comum 256, saída 64 tokens. O candidato usa contexto nativo 1024; orçamento da TUI 256. Casos humanos longos não entram no acerto exato pareado.

Amostragem humana em lotes homogêneos: fração esperada 0.02; 1824 exemplos processados com repetição, 250267 tokens-alvo humanos. Validação humana de loss: 2 exemplos, insuficiente para qualidade geral.

Loss humana de referência: inicial 5.0858; final 5.8519. A loss agregada dominada por templates não comprova melhora no diálogo humano.

Validação sintética, acerto exato: referência 371/535; checkpoint SFT selecionado no passo 1200: 463/535. Critério: Conversas com histórico gerado pelo modelo após o contexto inicial: igualdade exata após strip, greedy, 64 tokens. Não é qualidade geral.

Seleção do checkpoint: Melhor por loss primeiro; final somente se passar todos os critérios fixos. Ambos avaliados na mesma validação; não é teste cego.

Decisão experimental: Reprovado; padrão da TUI preservado. Pelo menos um critério fixo falhou.

Candidato final, passo 6000: 459/535. Famílias abaixo de 80%: conversation_capability: 15/26; conversation_clarify: 25/38; conversation_definition: 14/32; conversation_social_context: 15/24; conversation_social: 14/24.

Referência: retenção dos casos anteriores 325/415; currículo novo 46/120.

Candidato: retenção dos casos anteriores 361/415; currículo novo 102/120.

Regressões conhecidas com contexto nativo e histórico gerado: checkpoint selecionado 6/6; checkpoint final 6/6. Exigência: 6/6, sem queda agregada nos casos anteriores e pelo menos 80% em cada família de conversa. Resultado: não atingido.

Referência comparativa: ai/runs/conversation-social-context-2026-11-02/best.pt. Loss de treino em 128 exemplos (amostra fixa sem reposição, seed 43); validação em todo o split.

Acertos por tarefa: conversation_capability: 19/26; conversation_memory: 95/96; conversation_repeat: 46/46; conversation_clarify: 27/38; conversation_repair: 33/33; conversation_definition: 29/32; conversation_identity: 8/8; conversation_insufficient: 13/16; conversation_social_context: 15/24; conversation_social: 15/24; conversation_guidance: 61/72; conversation_wellbeing: 43/48; conversation_composed: 35/48; conversation_misunderstanding: 12/12; conversation_closure: 12/12.

Critério exploratório: Conversas sintéticas: ao menos 80% em cada família, com histórico gerado pelo modelo. Resultado: não atingido. Não é aprovação de uso em documentos completos.

A sequência gerada na interface está na seção 5. As respostas completas da validação estão no JSON de avaliação da execução.

4. Interpretação e limites

Piloto de conversas e respostas humanas limitadas pelo contexto. Templates do assistente, sem revisão humana local. Repetições de prefixos no treino são intencionais; conversas e árvores humanas não atravessam splits. Acerto exato penaliza paráfrases válidas e não mede inteligência geral. Validação seleciona pesos; não é teste cego. Janela nativa 1024, orçamento de geração 256 tokens. O modelo pode esquecer, inventar ou responder fora do pedido.

Não foram usados TCCs candidatos nesta execução. Não há avaliação de notas de apresentação, uso com simulador aberto ou confiabilidade de documentos completos. Tempos referem-se ao laço e incluem avaliação; preparação é separada. Métricas de memória não representam toda a memória do Mac.

Rastreabilidade: run.json, summary.json, metrics.jsonl e amostras/comparison.json quando presentes, na pasta ai/runs/conversation-robust-2026-11-02.

5. Regressões de conversa observadas na interface

Prompts derivados das falhas relatadas pelo usuário; não são um benchmark cego. Respostas geradas sem edição, mantendo histórico da própria rede até a limpeza da sessão.

Você: ola

Modelo: Olá! Sou o Confere.

Você: vc esta bem?

Modelo: Estou pronto para ajudar. E você?

Você: qual seu nome? diga 3 vezes

Modelo: Confere Confere Confere

Você: fala pfv

Modelo: Confere Confere Confere

Você: bugou?

Modelo: Entendi errado. Pode reformular o pedido?

Você: nada ue

Modelo: Tudo bem. Podemos conversar quando você quiser.

O ganho em templates não comprova linguagem geral, cumprimento de pedidos compostos ou memória confiável para nomes novos. Não houve aprovação de uso como assistente geral.