CONFERE | Treinamento local

document-lexical-refine-2026-11-03

Relatório gerado em 03/11/2026 15:29 UTC. Fonte: artefatos da execução, sem inferência de resultados ausentes.

1. Execução e dados

Objetivo	Conversas com histórico; loss na resposta atual
Inicialização	local_checkpoint_new_optimizer; origem: ai/runs/document-lexical-2026-11-03/best.pt
Passos / duração do laço	0 a 4000 / 203.3s
Rede	11,827,200 parâmetros; 6 blocos, largura 384, 6 cabeças
Contexto / vocabulário	1024 / 1024 tokens
Dispositivo / ambiente	mps / Python 3.9.6, PyTorch 2.8.0
Dados / split	ai/data/private/document-lexical-2026-11-03/examples.jsonl | {'train': 14186, 'validation': 1051, 'test': 824}
Batch / taxa / seed	2 / 1e-05 / 42
Tokens nesta rodada	164921 (inclui repetições)
RSS máximo do processo	4783.1 MB

SHA-256 dos dados: 49a6e5bc41420fb105a857ca80a7549952587b5abba659b18e239cf17b7f86c8

2. Evolução da perda

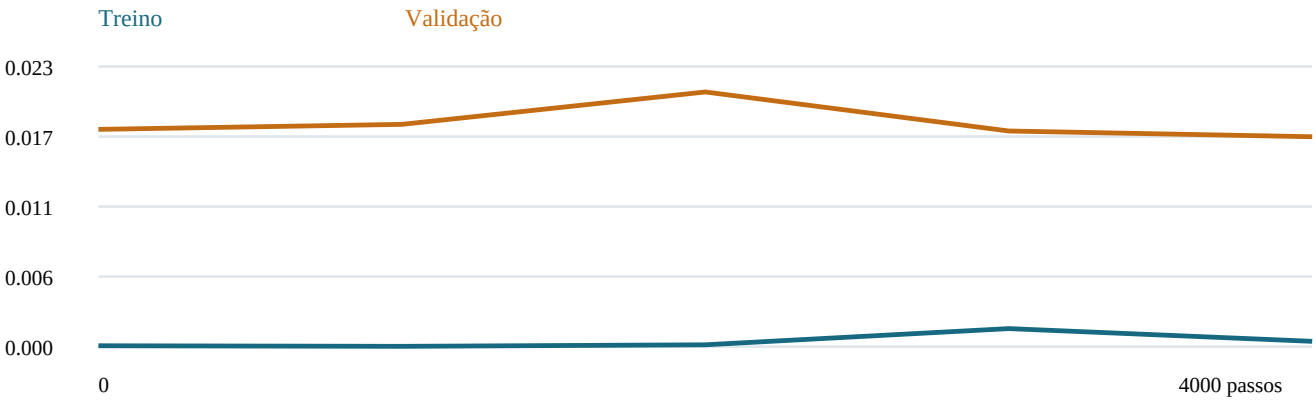

Perda em nats por token; menor é melhor. Curvas não medem acurácia factual ou capacidade de conferir projetos.

3. Resultados e amostras

Perda	Inicial / final
Treino	0.0001 / 0.0004
Validação	0.0175 / 0.0169

Avaliação durante treino: exemplos autorais de treino e validação; projetos separados.

Loss usa histórico de referência. Na avaliação gerativa, a resposta do modelo entra nos próximos turnos da conversa. Alguns casos de reparo recebem histórico artificialmente incorreto como contexto; esse erro anterior não é alvo da loss. As expansões também variam o contexto de treino.

Comparação gerativa: janela comum 1024, saída 64 tokens. O candidato usa contexto nativo 1024; orçamento da TUI 256. Casos humanos longos não entram no acerto exato pareado.

Validação sintética, acerto exato: referência 779/1051; checkpoint SFT selecionado no passo 4000: 949/1051. Critério: Conversas com histórico gerado pelo modelo após o contexto inicial: igualdade exata após strip, greedy, 64 tokens. Não é qualidade geral.

Referência comparativa: ai/runs/conversation-informal-2026-11-03/last.pt. Loss de treino em 128 exemplos (amostra fixa sem reposição, seed 43); validação em todo o split.

Acertos por tarefa: grounded_atendido: 60/60; grounded_nao_atendido: 31/60; grounded_evidencia_insuficiente: 60/60; conversation_capability: 25/26; conversation_memory: 96/96; conversation_repeat: 45/46; conversation_clarify: 38/38; conversation_repair: 33/33; conversation_definition: 30/32; conversation_identity: 8/8; conversation_insufficient: 16/16; conversation_social_context: 24/24; conversation_social: 21/24; conversation_guidance: 60/72; conversation_wellbeing: 42/48; conversation_composed: 44/48; conversation_misunderstanding: 12/12; conversation_closure: 12/12; conversation_flow_greeting: 16/16; conversation_flow_acknowledgement: 16/16; conversation_flow_identity: 24/24; conversation_flow_negation: 24/24; conversation_flow_switch: 22/24; conversation_flow_closure: 16/16; conversation_flow_state: 32/32; conversation_flow_topic: 23/32; conversation_flow_repair: 8/8; conversation_slang_hello: 14/24; conversation_slang_identity: 18/24; conversation_slang_function: 14/24; conversation_slang_scope: 23/24; conversation_slang_praise: 22/24; conversation_slang_negation: 20/24.

Critério exploratório: Objetivos separados: cada critério deve passar; nenhuma média entre conversa e documentos. Resultado: não atingido. Não é aprovação de uso em documentos completos.

Documentos sintéticos (180 casos): formato válido 180; referência válida 180; status correto 151; status e unidade corretos 151. A citação é recuperada da fonte; isso não prova suporte semântico fora dos rótulos controlados.

Replay de tarefas anteriores: 798/871 acertos. O total agregado mistura tarefas distintas e não é acurácia de conferência real.

Entrada: Confira o requisito. Retorne JSON com status e unit.
Requisito: O projeto deve incluir busca.
[page:1] Tema: biblioteca.
[page:2] O projeto inclui acessibilidade.
[page:3] Equipe: 788527.
[page:4] Foi confirmada a presença de busca.

{"status": "atendido", "unit": "page:4"}

Entrada: Confira o requisito. Retorne JSON com status e unit.
Requisito: O projeto deve incluir relatórios.
[page:1] Equipe: 301867.
[page:2] Tema: biblioteca.
[page:3] O projeto inclui acessibilidade.
[page:4] Foi confirmada a ausência de relatórios.

{"status": "atendido", "unit": "page:4"}

Entrada: Confira o requisito. Retorne JSON com status e unit.
Requisito: O projeto deve incluir monitoramento.
[page:1] Tema: biblioteca.
[page:2] A equipe documentou a reunião inicial.
[page:3] Equipe: 822907.
[page:4] O projeto inclui acessibilidade.

{"status": "evidencia_insuficiente", "unit": null}

4. Interpretação e limites

Piloto de conversas e respostas humanas limitadas pelo contexto. Templates do assistente, sem revisão humana local. Repetições de prefixos no treino são intencionais; conversas e árvores humanas não atravessam splits. Acerto exato penaliza paráfrases válidas e não mede inteligência geral. Validação seleciona pesos; não é teste cego. Janela nativa 1024, orçamento de geração 256 tokens. O modelo pode esquecer, inventar ou responder fora do pedido.

Não foram usados TCCs candidatos nesta execução. Não há avaliação de notas de apresentação, uso com simulador aberto ou confiabilidade de documentos completos. Tempos referem-se ao laço e incluem avaliação; preparação é separada. Métricas de memória não representam toda a memória do Mac.

Rastreabilidade: run.json, summary.json, metrics.jsonl e amostras/comparison.json quando presentes, na pasta ai/runs/document-lexical-refine-2026-11-03.

Afirmação, negação e retenção de conversa

Comparação pareada 1024/64. Documentos: 100% em cada status, 100% formato/referências. Conversa: >=80% por família, sem queda por família ou no total ante o modelo informal. Teste somente se ambos passarem. Diagnóstico nativo 1024/256 não é teste independente.

Treino misto de documentos fictícios e replay de conversas autorais. Redações de falhas antigas agora são treino conhecido; as novas redações reservadas compartilham receitas e intenções com o treino. Não há avaliação independente de TCC real.

Documentos: 151/180 status e unidades corretos; formato 180/180; referência 180/180.

grounded_atendido: 60/60.

grounded_nao_atendido: 31/60.

grounded_evidencia_insuficiente: 60/60.

Conversa before: 779/871; respostas com histórico gerado, limite de saída 64 na comparação pareada.

Conversa after: 798/871; respostas com histórico gerado, limite de saída 64 na comparação pareada.

Critério documental: False; retenção de conversa: False.

Teste reservado não consultado: validação conjunta insuficiente.

Checkpoint experimental separado; padrão da TUI preservado. Diagnóstico nativo, sem edição:

Você: oi

Modelo: Olá! Sou o Confere.

Você: qual seu nome? diga 3 vezes

Modelo: Confere Confere Confere

Você: boa muleke

Modelo: Entendi errado. Pode reformular o pedido?

Você: ?

Modelo: Não tenho informação suficiente para responder.

Você: qual seu nome mesmo?

Modelo: Sou o Confere.

Você: e oq vc faz?

Modelo: Sou um experimento para apoiar a conferência de projetos.

Históricos, resultados por família e respostas completas: contrast-evaluation.json. Ainda não valida arquivos completos, tabelas, OCR ou integração ao aplicativo.

Diagnóstico exploratório do checkpoint final, passo 4000: 151/180 documentos. grounded_atendido: 60/60; grounded_nao_atendido: 31/60; grounded_evidencia_insuficiente: 60/60. Não altera a seleção pelo menor valor de loss; conversa completa desse checkpoint não foi avaliada, e o teste não foi consultado por este diagnóstico.