CONFERE | Treinamento local

document-long-contrasts-2026-11-04

Relatório gerado em 04/11/2026 15:10 UTC. Fonte: artefatos da execução, sem inferência de resultados ausentes.

1. Execução e dados

Objetivo	Conversas com histórico; loss na resposta atual
Inicialização	local_checkpoint_new_optimizer; origem: ai/runs/document-long-2026-11-04/best.pt
Passos / duração do laço	0 a 2400 / 345.9s
Rede	11,827,200 parâmetros; 6 blocos, largura 384, 6 cabeças
Contexto / vocabulário	1024 / 1024 tokens
Dispositivo / ambiente	mps / Python 3.9.6, PyTorch 2.8.0
Dados / split	ai/data/private/document-long-contrasts-v2-2026-11-04/examples.jsonl | {'validation': 1195, 'test': 824, 'train': 13400}
Batch / taxa / seed	2 / 1e-05 / 42
Tokens nesta rodada	110863 (inclui repetições)
RSS máximo do processo	3867.5 MB

SHA-256 dos dados: df80c1ee52205ff72356ca194f7d7818be8a195b32d2604625c656859345f4ad

2. Evolução da perda

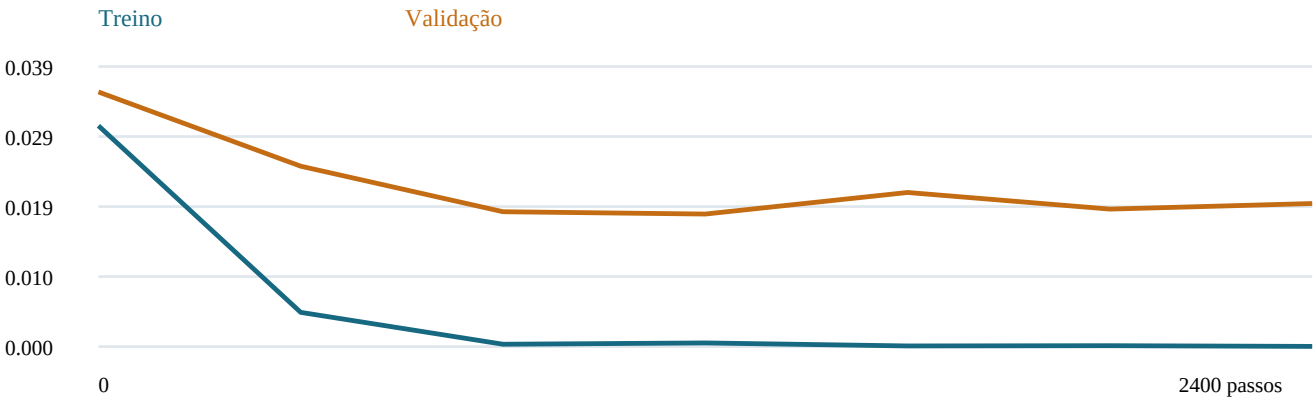

Perda em nats por token; menor é melhor. Curvas não medem acurácia factual ou capacidade de conferir projetos.

3. Resultados e amostras

Perda	Inicial / final
Treino	0.0307 / 0.0000
Validação	0.0354 / 0.0199

Avaliação durante treino: exemplos autorais de treino e validação; projetos separados.

Loss usa histórico de referência. Na avaliação gerativa, a resposta do modelo entra nos próximos turnos da conversa. Alguns casos de reparo recebem histórico artificialmente incorreto como contexto; esse erro anterior não é alvo da loss. As expansões também variam o contexto de treino.

Comparação gerativa: janela comum 1024, saída 64 tokens. O candidato usa contexto nativo 1024; orçamento da TUI 256. Casos humanos longos não entram no acerto exato pareado.

Lotes documentais explícitos: fração esperada 0.45; processados 2092 exemplos e 61231 tokens-alvo, incluindo repetição. A fração de lotes não é proporção de tokens nem de casos únicos.

Validação sintética, acerto exato: referência 1024/1195; checkpoint SFT selecionado no passo 1200: 1102/1195. Critério: Conversas com histórico gerado pelo modelo após o contexto inicial: igualdade exata após strip, greedy, 64 tokens. Não é qualidade geral.

Referência comparativa: ai/runs/document-long-2026-11-04/best.pt. Loss de treino em 128 exemplos (amostra fixa sem reposição, seed 43); validação em todo o split.

Acertos por tarefa: grounded_atendido: 97/108; grounded_nao_atendido: 102/108; grounded_evidencia_insuficiente: 107/108; conversation_capability: 25/26; conversation_memory: 96/96; conversation_repeat: 46/46; conversation_clarify: 37/38; conversation_repair: 33/33; conversation_definition: 28/32; conversation_identity: 8/8; conversation_insufficient: 16/16; conversation_social_context: 24/24; conversation_social: 21/24; conversation_guidance: 58/72; conversation_wellbeing: 37/48; conversation_composed: 37/48; conversation_misunderstanding: 12/12; conversation_closure: 12/12; conversation_flow_greeting: 16/16; conversation_flow_acknowledgement: 16/16; conversation_flow_identity: 24/24; conversation_flow_negation: 24/24; conversation_flow_switch: 24/24; conversation_flow_closure: 16/16; conversation_flow_state: 30/32; conversation_flow_topic: 26/32; conversation_flow_repair: 8/8; conversation_slang_hello: 16/24; conversation_slang_identity: 20/24; conversation_slang_function: 17/24; conversation_slang_scope: 24/24; conversation_slang_praise: 24/24; conversation_slang_negation: 21/24.

Critério exploratório: Objetivos separados: cada critério deve passar; nenhuma média entre conversa e documentos. Resultado: não atingido. Não é aprovação de uso em documentos completos.

Documentos sintéticos (324 casos): formato válido 323; referência válida 323; status correto 319; status e unidade corretos 306. A citação é recuperada da fonte; isso não prova suporte semântico fora dos rótulos controlados.

Replay de tarefas anteriores: 796/871 acertos. O total agregado mistura tarefas distintas e não é acurácia de conferência real.

Entrada: Confira o requisito. Retorne JSON com status e unit.
Requisito: O projeto deve incluir busca.
[page:1] Tema: biblioteca.
[page:2] O projeto inclui acessibilidade.
[page:3] Equipe: 788527.
[page:4] Foi confirmada a presença de busca.

{"status": "atendido", "unit": "page:4"}

Entrada: Confira o requisito. Retorne JSON com status e unit.
Requisito: O projeto deve incluir relatórios.
[page:1] Equipe: 301867.
[page:2] Tema: biblioteca.
[page:3] O projeto inclui acessibilidade.
[page:4] Foi confirmada a ausência de relatórios.

{"status": "nao_atendido", "unit": "page:4"}

Entrada: Confira o requisito. Retorne JSON com status e unit.
Requisito: O projeto deve incluir monitoramento.
[page:1] Tema: biblioteca.
[page:2] A equipe documentou a reunião inicial.
[page:3] Equipe: 822907.
[page:4] O projeto inclui acessibilidade.

{"status": "evidencia_insuficiente", "unit": null}

4. Interpretação e limites

Piloto de conversas e respostas humanas limitadas pelo contexto. Templates do assistente, sem revisão humana local. Repetições de prefixos no treino são intencionais; conversas e árvores humanas não atravessam splits. Acerto exato penaliza paráfrases válidas e não mede inteligência geral. Validação seleciona pesos; não é teste cego. Janela nativa 1024, orçamento de geração 256 tokens. O modelo pode esquecer, inventar ou responder fora do pedido.

Não foram usados TCCs candidatos nesta execução. Não há avaliação de notas de apresentação, uso com simulador aberto ou confiabilidade de documentos completos. Tempos referem-se ao laço e incluem avaliação; preparação é separada. Métricas de memória não representam toda a memória do Mac.

Rastreabilidade: run.json, summary.json, metrics.jsonl e amostras/comparison.json quando presentes, na pasta ai/runs/document-long-contrasts-2026-11-04.

Contextos longos e arquivos completos

Selecionado por menor loss. Documentos curtos: 100% por status. Longos: >=90% por status. Ambos: 100% formato/referências. Conversa: >=80% por família, sem queda por família ou agregado ante a origem, janela 1024/64. Piloto completo: todos os rótulos, conflito do backup, citações com as frases autorais corretas e zero saída inválida. Nenhuma promoção automática ou abertura do teste neste experimento.

Validação autoral, receitas compartilhadas. Piloto completo já conhecido pelo diagnóstico, fora do gradiente mas não independente. Citação literal não prova suporte semântico. Checkpoint e padrão da TUI preservados separadamente.

long_documents: origem 87/144; selecionado 126/144.

Formato 143/144; referências 143/144. grounded_atendido: 37/48; grounded_nao_atendido: 42/48; grounded_evidencia_insuficiente: 47/48

short_documents: origem 168/180; selecionado 180/180.

Formato 180/180; referências 180/180. grounded_atendido: 60/60; grounded_nao_atendido: 60/60; grounded_evidencia_insuficiente: 60/60

conversation: origem 769/871; selecionado 796/871.

Famílias abaixo de 80%: conversation_wellbeing: 37/48; conversation_composed: 37/48; conversation_slang_hello: 16/24; conversation_slang_function: 17/24.

Regressões por família ante a origem: conversation_flow_topic: 29/32 para 26/32.

pilot_before: evidencia_insuficiente, evidencia_insuficiente, evidencia_insuficiente. Saídas inválidas: 9; citações literais: 48; com suporte às frases autorais do piloto: 0.

pilot_after: evidencia_insuficiente, evidencia_insuficiente, evidencia_insuficiente. Saídas inválidas: 3; citações literais: 18; com suporte às frases autorais do piloto: 0.

Critérios: short_documents: True; long_documents: False; conversation: False; full_files: False.

Teste reservado não consultado; padrão da TUI preservado. Piloto com PDF textual e DOCX fictícios: não valida TCC real, OCR ou aplicativo.

long-validation-3 | Esperado: {"status": "atendido", "unit": "page:1"}

Modelo: {"status": "atendido", "unit": "page:2"}

long-validation-39 | Esperado: {"status": "atendido", "unit": "page:1"}

Modelo: {"status": "atendido", "unit": "page:2"}

long-validation-42 | Esperado: {"status": "atendido", "unit": "page:1"}

Modelo: {"status": "atendido", "unit": "page:3"}