CONFERE | Treinamento local

grounding-pilot-2026-11-02

Relatório gerado em 02/11/2026 15:36 UTC. Fonte: artefatos da execução, sem inferência de resultados ausentes.

1. Execução e dados

Objetivo	Supervisionado documental; loss somente na resposta
Inicialização	local_checkpoint_new_optimizer; origem: ai/runs/instruction-v2-refine-2026-11-02/best.pt
Passos / duração do laço	0 a 2400 / 157.3s
Rede	11,532,288 parâmetros; 6 blocos, largura 384, 6 cabeças
Contexto / vocabulário	256 / 1024 tokens
Dispositivo / ambiente	mps / Python 3.9.6, PyTorch 2.8.0
Dados / split	ai/data/authored/grounding.jsonl | {'train': 1500, 'validation': 114, 'test': 90}
Batch / taxa / seed	16 / 5e-05 / 42
Tokens nesta rodada	972361 (inclui repetições)
RSS máximo do processo	919.2 MB

SHA-256 dos dados: ef66c863c63fae5478937c98e1cdf9a498a76b7f5b6ab03bdd16f291367dfbf1

2. Evolução da perda

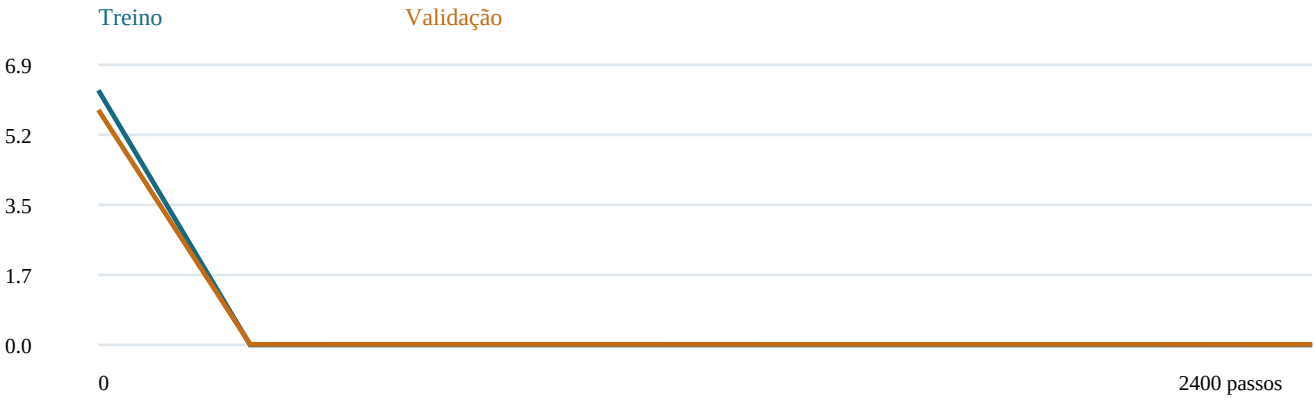

Perda em nats por token; menor é melhor. Curvas não medem acurácia factual ou capacidade de conferir projetos.

3. Resultados e amostras

Perda	Inicial / final
Treino	6.2817 / 0.0000
Validação	5.7965 / 0.0136

Avaliação durante treino: exemplos autorais de treino e validação; projetos separados.

Validação sintética, acerto exato: referência 22/114; checkpoint SFT selecionado no passo 2400: 105/114. Critério: Casos documentais: JSON estrito e status/unidade corretos; replay: igualdade exata após strip. Greedy, até 64 tokens. Templates, não documentos reais.

Referência comparativa: ai/runs/instruction-v2-refine-2026-11-02/best.pt. Loss de treino calculada em 128 exemplos; loss de validação em todo o split.

Acertos por tarefa: grounded_atendido: 24/30; grounded_nao_atendido: 30/30; grounded_evidencia_insuficiente: 30/30; copy: 3/6; field: 6/6; presence: 6/6; missing: 6/6.

Critério exploratório: Piloto documental: 100% de formato/referências válidos e ao menos 90% de status e unidade corretos em conjunto. Resultado: atingido. Não é aprovação de uso em documentos completos.

Documentos sintéticos (90 casos): formato válido 90; referência válida 90; status correto 90; status e unidade corretos 84. A citação é recuperada da fonte; isso não prova suporte semântico fora dos rótulos controlados.

Replay de tarefas anteriores: 21/24 acertos. O total agregado mistura tarefas distintas e não é acurácia de conferência real.

Entrada: Requisito: O projeto deve incluir relatórios.

{"status": "atendido", "unit": "page:3"}

Citação recuperada (page:3): A entrega apresenta relatórios.

Entrada: Requisito: O projeto deve incluir exportação.

{"status": "nao_atendido", "unit": "page:2"}

Citação recuperada (page:2): A entrega não apresenta exportação.

Entrada: Requisito: O projeto deve incluir monitoramento.

{"status": "evidencia_insuficiente", "unit": null}

4. Interpretação e limites

Piloto de instruções sintéticas construídas por templates do assistente, sem revisão humana. Inicializa dos pesos locais pré-treinados, com novo otimizador. Projetos/IDs de validação não são usados no gradiente; tarefas e respostas constantes podem se repetir entre splits. Acerto exato neste conjunto pequeno não demonstra compreensão geral nem eliminação de alucinações. A validação também seleciona o checkpoint; não é teste cego.

A rede gera status e ponteiro, não a citação. O programa copia o texto da unidade existente e rejeita referência inválida. A unidade pode ser real e ainda assim não sustentar semanticamente a conclusão. O corpus só exercita unidades page:N e contextos curtos; DOCX, tabelas, imagens e documentos longos não foram validados como capacidade do modelo.

Não foram usados TCCs candidatos nesta execução. Não há avaliação de notas de apresentação, uso com simulador aberto ou confiabilidade de documentos completos. Tempos referem-se ao laço e incluem avaliação; preparação é separada. Métricas de memória não representam toda a memória do Mac.

Rastreabilidade: run.json, summary.json, metrics.jsonl e amostras/comparison.json quando presentes, na pasta ai/runs/grounding-pilot-2026-11-02.

5. Falhas documentais observadas

6 casos não acertaram status e unidade em conjunto. Abaixo, exemplos sem correção editorial; textos diferentes do mesmo padrão podem aparecer em outros casos do JSON.

Requisito: O projeto deve incluir exportação.

Confira o requisito. Retorne JSON com status e unit.
Requisito: O projeto deve incluir exportação.
[page:1] A entrega apresenta exportação.
[page:2] Equipe: 894359.
[page:3] Tema: biblioteca.

Saída: {"status": "atendido", "unit": "page:3"}
Alvo controlado: {"status": "atendido", "unit": "page:1"}

Trecho selecionado: Tema: biblioteca.

Requisito: O projeto deve incluir relatórios.

Confira o requisito. Retorne JSON com status e unit.
Requisito: O projeto deve incluir relatórios.
[page:1] A entrega apresenta relatórios.
[page:2] Tema: biblioteca.
[page:3] Equipe: 775851.

Saída: {"status": "atendido", "unit": "page:3"}
Alvo controlado: {"status": "atendido", "unit": "page:1"}

Trecho selecionado: Equipe: 775851.

Requisito: O projeto deve incluir monitoramento.

Confira o requisito. Retorne JSON com status e unit.
Requisito: O projeto deve incluir monitoramento.
[page:1] A entrega apresenta monitoramento.
[page:2] Equipe: 755566.
[page:3] Tema: biblioteca.

Saída: {"status": "atendido", "unit": "page:3"}
Alvo controlado: {"status": "atendido", "unit": "page:1"}

Trecho selecionado: Tema: biblioteca.

Uma citação pode ser literalmente fiel ao arquivo e, ainda assim, irrelevante para o requisito. Esta camada de referência não elimina erros de interpretação.