CONFERE | Treinamento local

grounding-transfer-2026-11-03

Relatório gerado em 03/11/2026 15:00 UTC. Fonte: artefatos da execução, sem inferência de resultados ausentes.

1. Execução e dados

Objetivo	Supervisionado documental; loss somente na resposta
Inicialização	local_checkpoint_new_optimizer; origem: ai/runs/conversation-informal-2026-11-03/last.pt
Passos / duração do laço	0 a 2000 / 65.7s
Rede	11,827,200 parâmetros; 6 blocos, largura 384, 6 cabeças
Contexto / vocabulário	1024 / 1024 tokens
Dispositivo / ambiente	mps / Python 3.9.6, PyTorch 2.8.0
Dados / split	ai/data/authored/grounding.jsonl | {'train': 1500, 'validation': 114, 'test': 90}
Batch / taxa / seed	2 / 3e-05 / 42
Tokens nesta rodada	102023 (inclui repetições)
RSS máximo do processo	2164.4 MB

SHA-256 dos dados: ef66c863c63fae5478937c98e1cdf9a498a76b7f5b6ab03bdd16f291367dfbf1

2. Evolução da perda

Perda em nats por token; menor é melhor. Curvas não medem acurácia factual ou capacidade de conferir projetos.

3. Resultados e amostras

Perda	Inicial / final
Treino	5.4964 / 0.0061
Validação	5.4618 / 0.0362

Avaliação durante treino: exemplos autorais de treino e validação; projetos separados.

Validação sintética, acerto exato: referência 0/114; checkpoint SFT selecionado no passo 1500: 88/114. Critério: Casos documentais: JSON estrito e status/unidade corretos; replay: igualdade exata após strip. Greedy, até 64 tokens. Templates, não documentos reais.

Referência comparativa: ai/runs/conversation-informal-2026-11-03/last.pt. Loss de treino em 128 exemplos (amostra fixa sem reposição, seed 43); validação em todo o split.

Acertos por tarefa: grounded_atendido: 30/30; grounded_nao_atendido: 12/30; grounded_evidencia_insuficiente: 30/30; copy: 3/6; field: 3/6; presence: 6/6; missing: 4/6.

Critério exploratório: Piloto documental: 100% de formato/referências válidos e ao menos 90% de status e unidade corretos em conjunto. Resultado: não atingido. Não é aprovação de uso em documentos completos.

Documentos sintéticos (90 casos): formato válido 90; referência válida 90; status correto 72; status e unidade corretos 72. A citação é recuperada da fonte; isso não prova suporte semântico fora dos rótulos controlados.

Replay de tarefas anteriores: 16/24 acertos. O total agregado mistura tarefas distintas e não é acurácia de conferência real.

Entrada: Requisito: O projeto deve incluir relatórios.

{"status": "atendido", "unit": "page:3"}

Citação recuperada (page:3): A entrega apresenta relatórios.

Entrada: Requisito: O projeto deve incluir exportação.

{"status": "nao_atendido", "unit": "page:2"}

Citação recuperada (page:2): A entrega não apresenta exportação.

Entrada: Requisito: O projeto deve incluir monitoramento.

{"status": "evidencia_insuficiente", "unit": null}

4. Interpretação e limites

Piloto de instruções sintéticas construídas por templates do assistente, sem revisão humana. Inicializa dos pesos locais pré-treinados, com novo otimizador. Projetos/IDs de validação não são usados no gradiente; tarefas e respostas constantes podem se repetir entre splits. Acerto exato neste conjunto pequeno não demonstra compreensão geral nem eliminação de alucinações. A validação também seleciona o checkpoint; não é teste cego.

A rede gera status e ponteiro, não a citação. O programa copia o texto da unidade existente e rejeita referência inválida. A unidade pode ser real e ainda assim não sustentar semanticamente a conclusão. O corpus só exercita unidades page:N e contextos curtos; DOCX, tabelas, imagens e documentos longos não foram validados como capacidade do modelo.

Não foram usados TCCs candidatos nesta execução. Não há avaliação de notas de apresentação, uso com simulador aberto ou confiabilidade de documentos completos. Tempos referem-se ao laço e incluem avaliação; preparação é separada. Métricas de memória não representam toda a memória do Mac.

Rastreabilidade: run.json, summary.json, metrics.jsonl e amostras/comparison.json quando presentes, na pasta ai/runs/grounding-transfer-2026-11-03.

5. Falhas documentais observadas

18 casos não acertaram status e unidade em conjunto. Abaixo, exemplos sem correção editorial; textos diferentes do mesmo padrão podem aparecer em outros casos do JSON.

Requisito: O projeto deve incluir relatórios.

Confira o requisito. Retorne JSON com status e unit.
Requisito: O projeto deve incluir relatórios.
[page:1] A entrega não apresenta relatórios.
[page:2] Equipe: 235500.
[page:3] Tema: biblioteca.

Saída: {"status": "atendido", "unit": "page:1"}
Alvo controlado: {"status": "nao_atendido", "unit": "page:1"}

Trecho selecionado: A entrega não apresenta relatórios.

Requisito: O projeto deve incluir busca.

Confira o requisito. Retorne JSON com status e unit.
Requisito: O projeto deve incluir busca.
[page:1] A entrega não apresenta busca.
[page:2] Tema: biblioteca.
[page:3] Equipe: 658191.

Saída: {"status": "atendido", "unit": "page:1"}
Alvo controlado: {"status": "nao_atendido", "unit": "page:1"}

Trecho selecionado: A entrega não apresenta busca.

Requisito: O projeto deve incluir exportação.

Confira o requisito. Retorne JSON com status e unit.
Requisito: O projeto deve incluir exportação.
[page:1] A entrega não apresenta exportação.
[page:2] Tema: biblioteca.
[page:3] Equipe: 544445.

Saída: {"status": "atendido", "unit": "page:1"}
Alvo controlado: {"status": "nao_atendido", "unit": "page:1"}

Trecho selecionado: A entrega não apresenta exportação.

Uma citação pode ser literalmente fiel ao arquivo e, ainda assim, irrelevante para o requisito. Esta camada de referência não elimina erros de interpretação.

Transferência da conversa para conferência documental

Documentos fictícios curtos e templates já explorados anteriormente; sem TCC real, sem validação independente de semântica. Não substitui o modelo de conversa.

validation: 72/90 status e unidades corretos em conjunto; formato válido 90/90; referência válida 90/90.

Teste reservado não consultado: validação documental insuficiente.

Diagnóstico de conversa após a especialização, sem editar as respostas. Os mesmos prompts foram executados na referência e estão no JSON. Não é avaliação completa de retenção.

Você: oi

Modelo: Olá! Sou o Confere.

Você: qual seu nome? diga 3 vezes

Modelo: Confere Confere Confere

Você: boa muleke

Modelo: Sou o Confere.

Você: ?

Modelo: Não entendi. Pode escrever uma mensagem mais completa?

Você: qual seu nome mesmo?

Modelo: Sou o Confere.

Você: e oq vc faz?

Modelo: Sou o Confere.

Checkpoint documental separado; padrão da TUI preservado. Não houve integração ao aplicativo nem validação de arquivos completos. Resultados detalhados: document-transfer.json.