CONFERE | Treinamento local

instruction-v2-2026-11-02

Relatório gerado em 02/11/2026 15:08 UTC. Fonte: artefatos da execução, sem inferência de resultados ausentes.

1. Execução e dados

Objetivo	Instruções sintéticas; loss somente na resposta
Inicialização	local_checkpoint_new_optimizer; origem: ai/runs/portuguese-expanded-2026-11-02/best.pt
Passos / duração do laço	0 a 3000 / 141.9s
Rede	11,532,288 parâmetros; 6 blocos, largura 384, 6 cabeças
Contexto / vocabulário	256 / 1024 tokens
Dispositivo / ambiente	mps / Python 3.9.6, PyTorch 2.8.0
Dados / split	ai/data/authored/instructions-v2.jsonl | {'train': 4044, 'validation': 168, 'test': 164}
Batch / taxa / seed	16 / 0.0001 / 42
Tokens nesta rodada	451709 (inclui repetições)
RSS máximo do processo	1270.5 MB

SHA-256 dos dados: e7b983a88280fdf7ed6b1e17a5cbf13683b4bc883e428e462829d85aaae82e8c

2. Evolução da perda

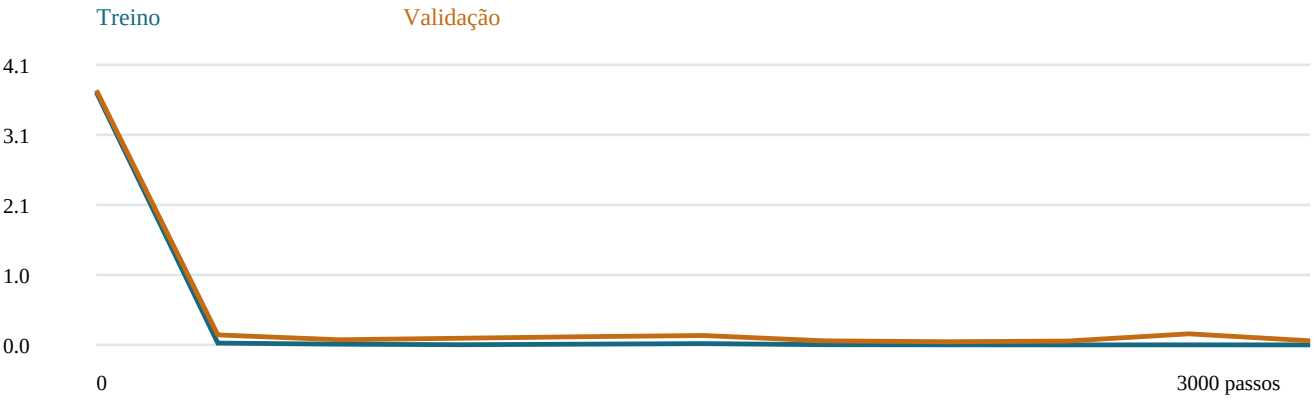

Perda em nats por token; menor é melhor. Curvas não medem acurácia factual ou capacidade de conferir projetos.

3. Resultados e amostras

Perda	Inicial / final
Treino	3.7297 / 0.0004
Validação	3.7611 / 0.0612

Avaliação durante treino: exemplos autorais de treino e validação; projetos separados.

Validação sintética, acerto exato: referência 37/168; checkpoint SFT selecionado no passo 2100: 151/168. Critério: Igualdade exata após strip; greedy, até 64 tokens. Validação de templates, não conversa geral.

Referência comparativa: ai/runs/instruction-pilot-2026-11-02/best.pt. Loss de treino calculada em 128 exemplos; loss de validação em todo o split.

Acertos por tarefa: copy: 29/40; field: 36/40; presence: 40/40; missing: 39/40; dialogue: 2/3; insufficient_context: 5/5.

Critério definido para substituir o piloto padrão: ao menos 80% em cada tarefa crítica (cópia, código, prazo/ausência e falta de contexto). Resultado: não atingido. Não é aprovação de uso em documentos completos.

Entrada: Reproduza fielmente a frase a seguir: O projeto 449 trata de agenda.

O projeto 4449 trata de agenda.

Entrada: Informe exclusivamente o identificador do campo Código: Autor: Equipe 449. Tema: agenda. Código: REQ-449.

REQ-449

Entrada: Verifique se uma data está presente; use SIM ou NÃO. Projeto 449. Tema: agenda.

NÃO

4. Interpretação e limites

Piloto de instruções sintéticas construídas por templates do assistente, sem revisão humana. Inicializa dos pesos locais pré-treinados, com novo otimizador. Projetos/IDs de validação não são usados no gradiente; tarefas e respostas constantes podem se repetir entre splits. Acerto exato neste conjunto pequeno não demonstra compreensão geral nem eliminação de alucinações. A validação também seleciona o checkpoint; não é teste cego.

Não foram usados TCCs candidatos nesta execução. Não há avaliação de notas de apresentação, uso com simulador aberto ou confiabilidade de documentos completos. Tempos referem-se ao laço e incluem avaliação; preparação é separada. Métricas de memória não representam toda a memória do Mac.

Rastreabilidade: run.json, summary.json, metrics.jsonl e amostras/comparison.json quando presentes, na pasta ai/runs/instruction-v2-2026-11-02.